의존성 과 파싱 알고리즘

복잡복작스핀 심상진

목차

1. 의존성 분석이란?
    1. 의존성 분석의 정의
    2. 자연어 처리에서 의존성 분석의 필요성
2. 의존성 분석을 위한 알고리즘
    1. Transition-based Dependency Parsing Algorithm
    2. Graph-based Dependency Parsing Algorithm
    3. 한국어에서 의존성 분석 상황

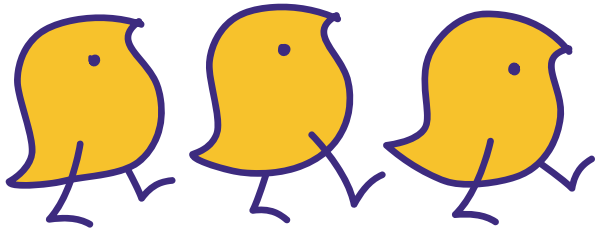

의존성 분석이란?

의존성 분석이란?

- 문장의 문법적 구조를 파악하여 각 단어별 관계성을 찾는 방법

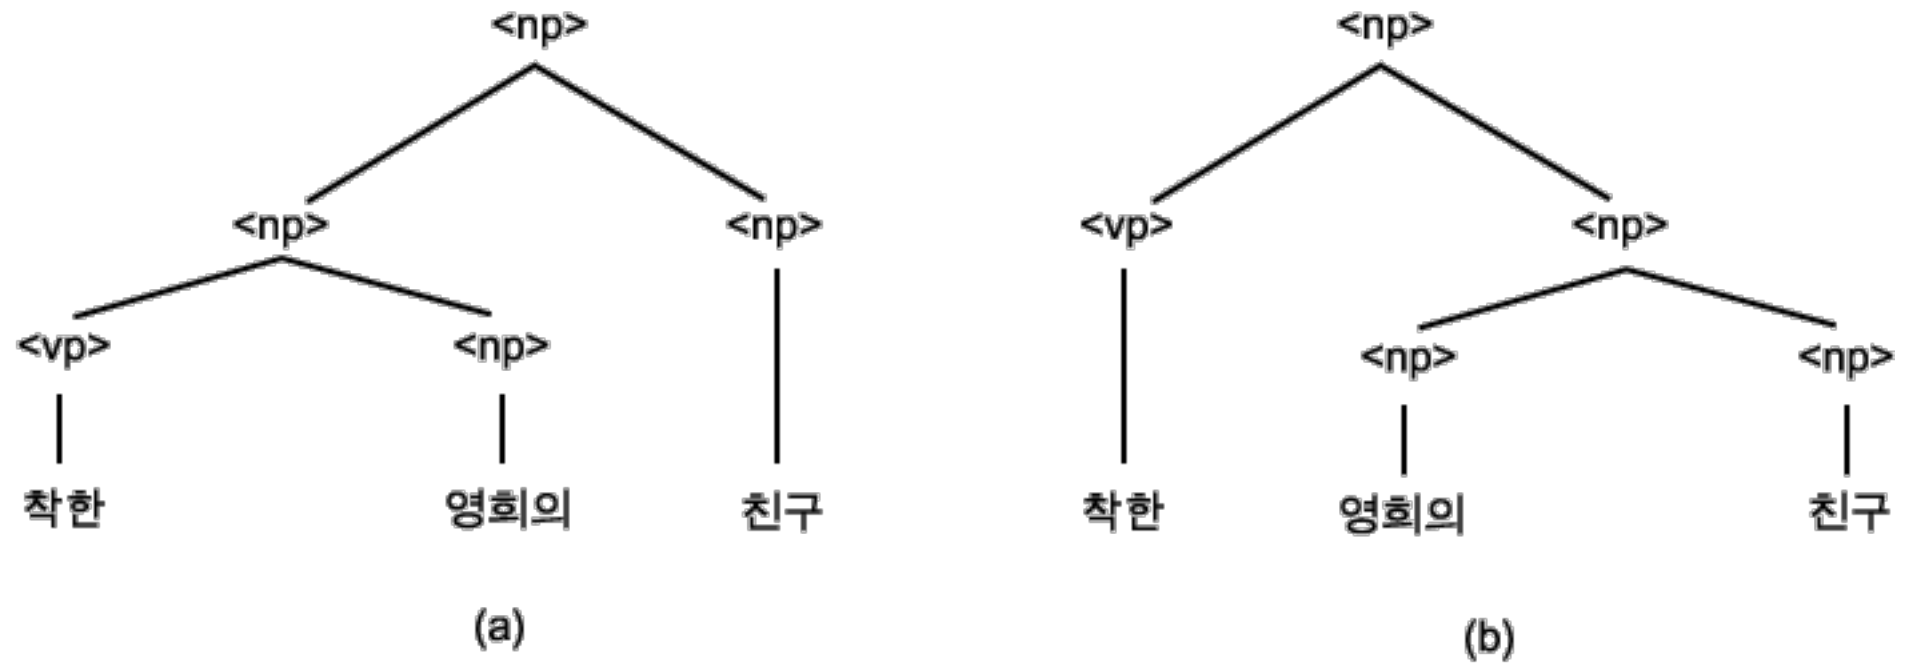

- 의존성 분석을 하는 이유 : 문장의 구조적 모호성을 해결하기 위해서 하고, 이를 통해서 다음의 것들을 하기 위함

Reference : http://www.aistudy.co.kr/linguistics/natural/language_kim.htm

의존성 분석이란?(Option)

- 프로그래밍 언어에서도 의존성 분석을 함.

1. 사용되지 않은 코드(또는 변수)를 찾기
2. 속도 최적화를 위한 정보 얻기
3. 코드 정적 분석을 위한 정보 얻기
4. 등등…

- 하지만 여기서는 자연어 처리를 대상으로 하니까…

자연어 처리에서 의존성 분석의 필요성

- Named-entity recognition (NER) is **the process of locating and classifying named entities** in a textual data into **predefined categories** such as the names of persons, organizations, locations, expressions of times, quantities, monetary values, percentages, etc.

  Ex) ***Donald Trump*** *will be visiting* ***New Delhi*** *next summer for a conference at* ***Google***

Reference : https://www.analyticsvidhya.com/blog/2017/12/introduction-computational-linguistics-dependency-trees/

자연어 처리에서 의존성 분석의 필요성

- **Coreference Resolution or Anaphora Resolution** is the task of finding all expressions that refer to the same entity in a text.

  Ex) "***I*** voted for ***Nader*** because ***he*** was most aligned with ***my*** values," ***she*** said.

  I, my -> she
  he -> Nader

Reference : https://www.analyticsvidhya.com/blog/2017/12/introduction-computational-linguistics-dependency-trees/

자연어 처리에서 의존성 분석의 필요성

- **Question Answering** systems based on computational linguistics **uses the syntactic structures of the query questions and matches them with the responses having similar syntactic structures.** The similar syntactic structures contribute the answer set to a particular question.

  Ex) Q: What is the capital of India?
  A: New Delhi is the capital of India

- Both the question and answer dependency trees have similar patterns and can be used to generate the answer responses to specific queries.

Reference : https://www.analyticsvidhya.com/blog/2017/12/introduction-computational-linguistics-dependency-trees/

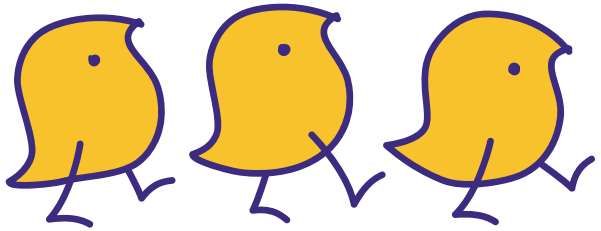

의존성 분석 알고리즘들

LangCon 2019

Dependency Tree Parsing Algorithm

- **비결정적 의존 구문 분석**(non-deterministic dependency parsing)은 문장이 가질 수 있는 **모든 의존트리(dependency tree)중에서 가장 높은 점수의 의존트리를 선택**하는 방법 : **그래프 기반 의존 구문 분석**(graph-based dependency parsing)
- **결정적 의존 구문 분석**(deterministic dependency parsing)은 **일종의 탐욕적 알고리즘**(greedy algorithm)에 기반한 방법으로 지역적 학습 모델(locally training model)을 사용 : **전이기반 의존 구문 분석**(transition-based dependency parsing)
- 결정적 의존 구문 분석은 비결정적 의존구문 분석보다 더 많은 문맥자질을 사용할 수 있고, 근거리 의존관계를 찾는데 강하며, 속도가 빠른 장점을 가지고 있다. 하지만 잘못 결정할 경우 오류의 전파가 발생하는 단점을 가짐

Reference : http://kiise.or.kr/e_journal/2014/1/SA/pdf/09.pdf

Transition-based Dependency Parsing

- Shift-Reduce dependency parsing과 유사
  - Shift : buffer에 있는 제일 앞에 있는 word 하나를 stack으로 옮기는 행동(action)
  - Reduce : stack에 있는 단어에 대해서 문법 규칙을 적용하고, 하나의 word만 남기는 행동(action)
  - Transition-based Dependency Parsing에서 Reduce는 Left Reduce(left-arc)와 Right Reduce(right-arc)의 두 종류가 있음
- Buffer : 토크나이징한 단어들 중에 파싱을 기다리는 단어들을 담고 있는 공간
- Stack : 토크나이징한 단어들 중에 파싱 작업을 진행 중인 단어들을 담고 있는 공간
- Parsing은 Buffer에 남아있는게 없으며, Stack에 하나의 Word만 남아있는 경우 끝남

Transition-based Dependency Parsing

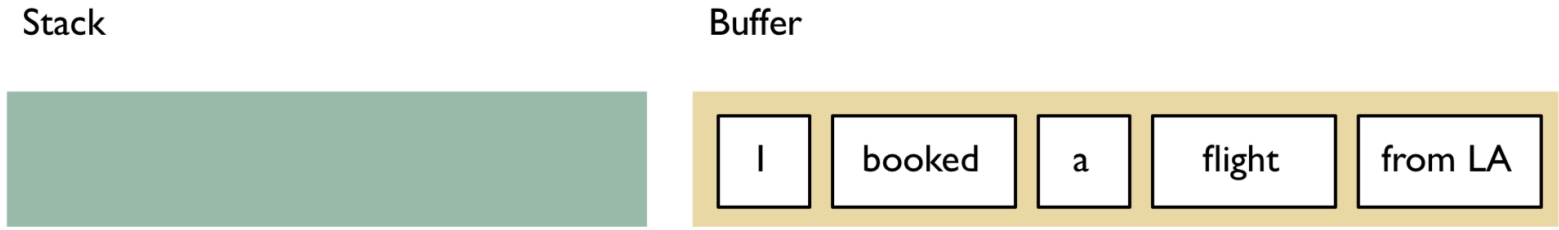

I booked a flight from LA

Transition-based Dependency Parsing

- Shift

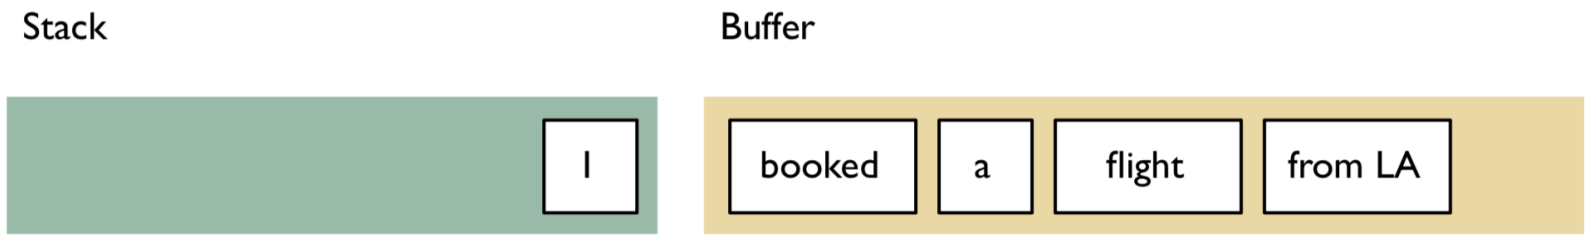

I booked a flight from LA

Transition-based Dependency Parsing

- Shift

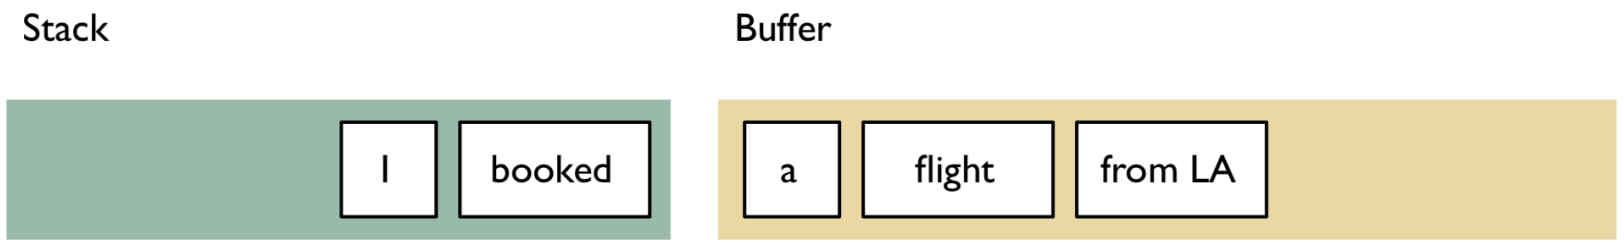

I booked a flight from LA

Transition-based Dependency Parsing

- Left-Reduce

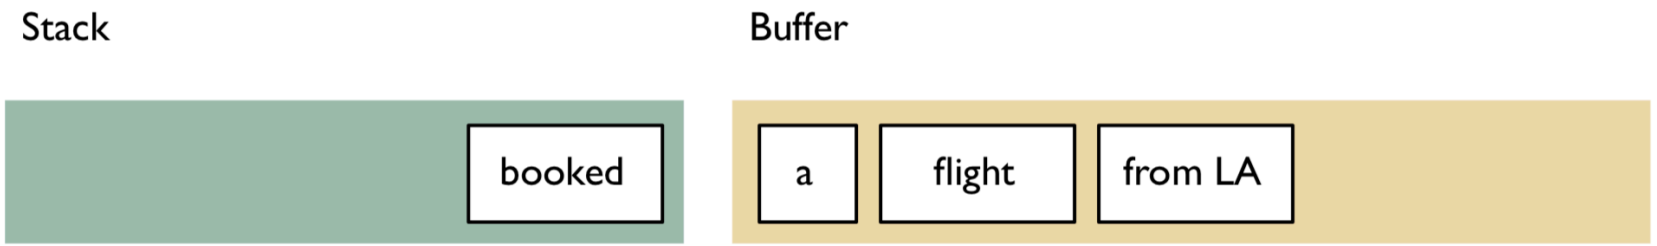

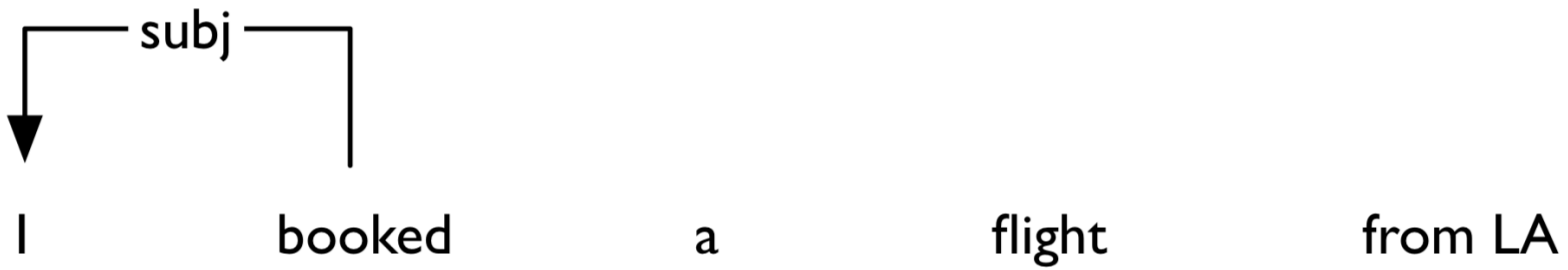

Transition-based Dependency Parsing

- Final State

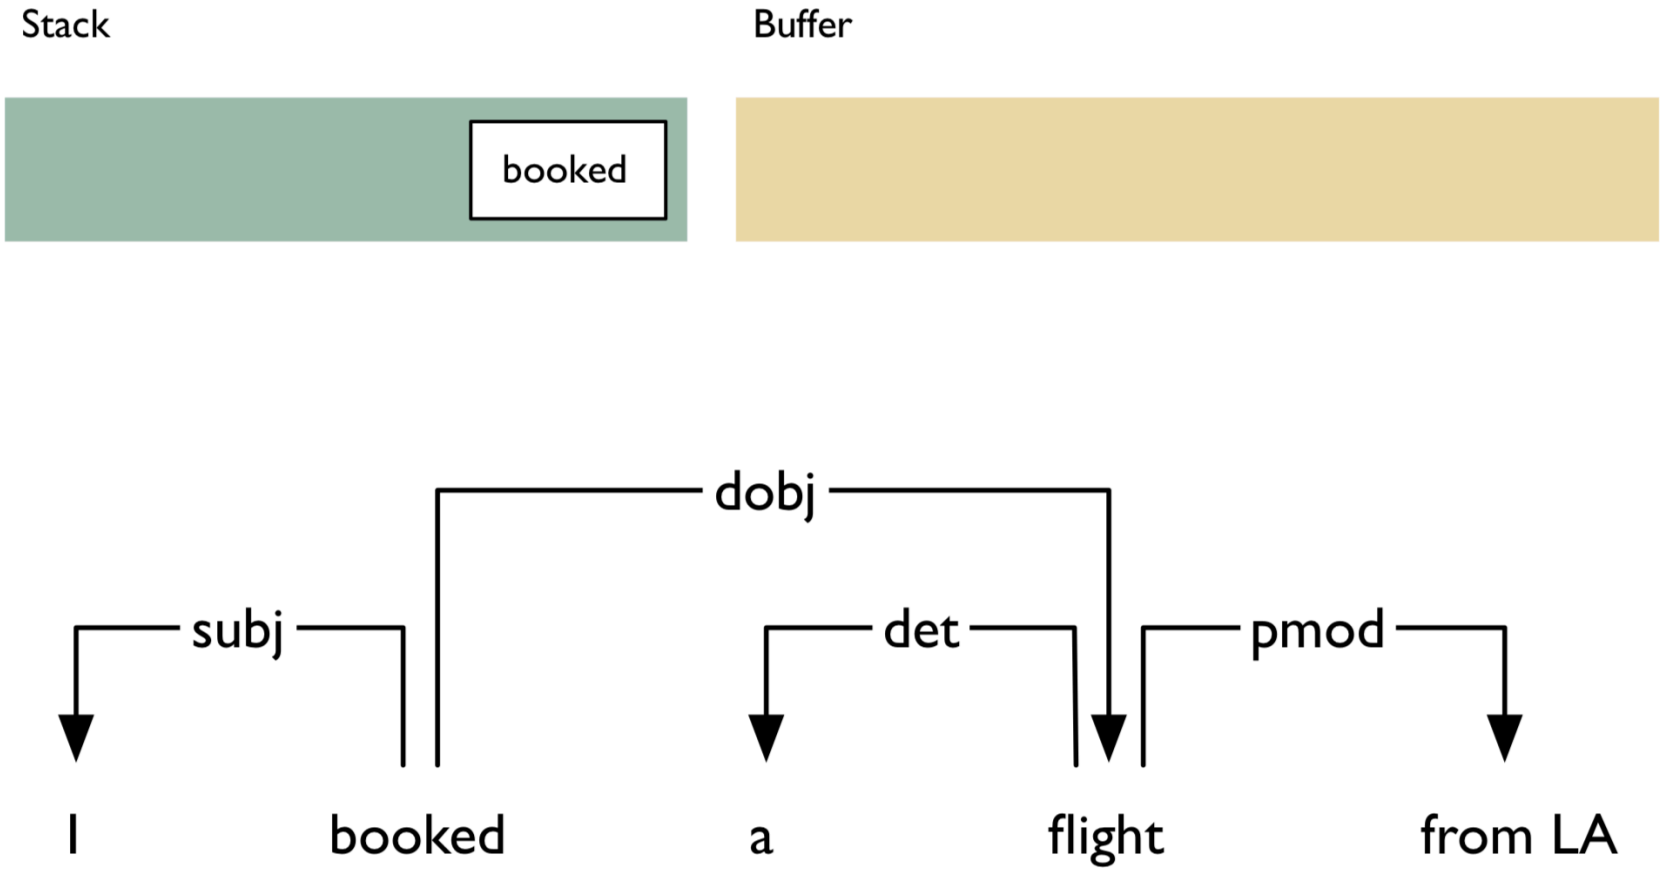

Transition-based Dependency Parsing

- Time complexity is linear, O(n), since we only have to treat each word once
- This can be achieved since the algorithm is greedy, and only builds one tree, in contrast to Eisner's algorithm, where all trees are explored
- There is no guarantee that we will even find the best tree given the model, with the arc-standard model
- There is a risk of error propagation
- An advantage is that we can use very informative features, for the ML algorithm

Transition-based Dependency Parsing – SyntaxNet

- Transition based parsing
  - [Google] SyntaxNet model

Start state	$([ROOT], [1, \dots, n], \{\})$
Final state	$(S, [\,], A)$
Transitions	
$\text{Left} - \text{Arc}_l$	$:= (\sigma \vert i, j \vert \beta, A) \Rightarrow (\sigma, j \vert \beta, A \cup \{(j, l, i)\})$
$\text{Right} - \text{Arc}_l^s$	$:= (\sigma \vert i, j \vert \beta, A) \Rightarrow (\sigma, i \vert \beta, A \cup \{(i, l, j)\})$
$Shift$	$:= (\sigma, i \vert \beta, A) \Rightarrow (\sigma \vert i, \beta, A)$
Preconditions	
$\text{Left} - \text{Arc}_l$	$\neg[\, i = ROOT\,]$
	$\neg\exists k \exists l'[\,(k, l', i) \in A\,]$
$\text{Right} - \text{Arc}_l^s$	$\neg\exists k \exists l'[\,(k, l', j) \in A\,]$

Arc-standard Transition

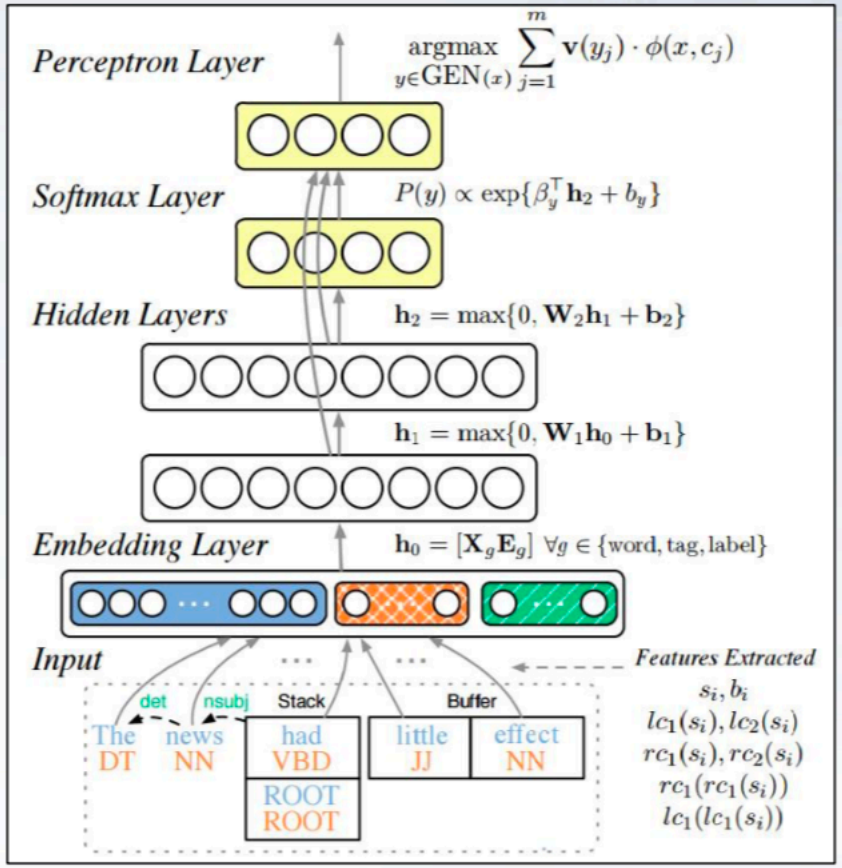

딥 러닝 기반 한국어 의존구문분석

- Transition-based + Backward
  - O(N)
  - 세종코퍼스 → 의존 구문 변환
    - 보조용언/의사보조용언 후처리
- Deep Learning 기반
  - ReLU(> Sigmoid) + Dropout
  - Korean Word Embedding
    - NNLM, Ranking(hinge, logit)
    - Word2Vec
  - Feature Embedding
    - POS (stack + buffer)
      - 자동 분석(오류 포함)
    - Dependency Label (stack)
    - Distance information
    - Valency information
    - Mutual Information
      - 대용량 코퍼스 → 자동 구문 분석

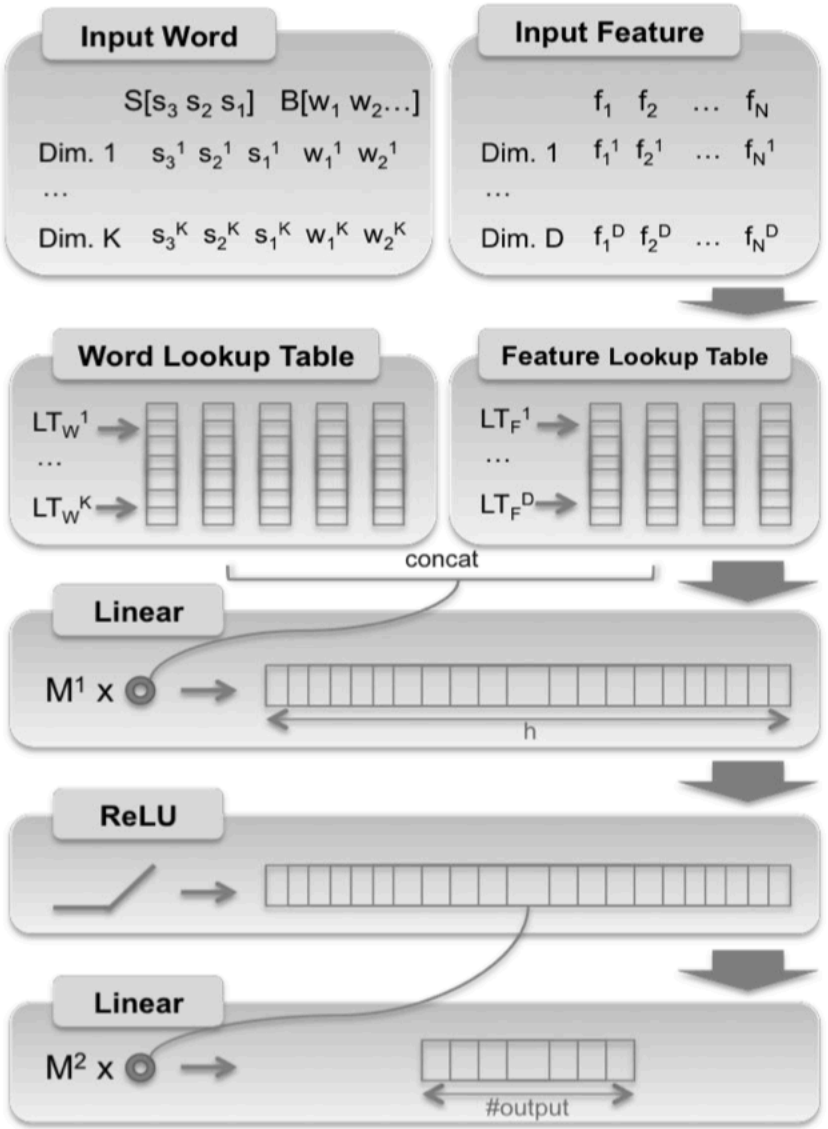

Transition-based Dependency Parsing

- Transition-based Dependency Parsing에서 전이방식을 결정(어떻게 묶는게 좋은지)하는 부분을 Deep Learning 기반 기계학습 기법을 이용하는 경우가 연구되고 있는 것 같음

- 오른쪽 테이블은 한국어에 그것들을 적용한 결과들

기존 의존 구문 분석	UAS	LAS
이용훈[15]: 국어정보베이스	88.42	-
오진영[16]: 세종코퍼스	87.03	-
임수종[17]: 세종코퍼스	88.15	-
J.D. Choi[18]: 세종코퍼스	85.47	83.47
박정열[19]: 세종코퍼스	86.43	-
안광모[20]: 세종코퍼스	87.52	-
딥 러닝+전이기반 의존 구문 분석 (세종코퍼스, 자동 분석 형태소 이용)	**UAS**	**LAS**
ReLU+dropout	89.56	87.35
NNLM+ReLU+dropout	90.05	87.87
NNLM+ReLU+MI feat.	89.91	87.58
NNLM+ReLU+dropout+MI feat.	**90.37**	**88.17**
NNLM+sigmoid+MI feat.	89.94	87.64
NNLM+sigmoid+dropout+MI feat.	90.27	88.03
Ranking(hinge loss)+ReLU+dropout +MI feat.	90.19	88.01
Ranking(logit loss)+ReLU+dropout +MI feat.	90.31	88.11
Word2vec+ReLU+dropout+MI feat.	90.27	87.97

Graph-based Dependency Parsing

- Dependency structure를 Graph(directed Tree)로 표현
  - Vertex: nodes (w_i, i번째 단어) 집합
  - Edge: arcs (w_i, w_j, l), l은 label: w_i →w_j

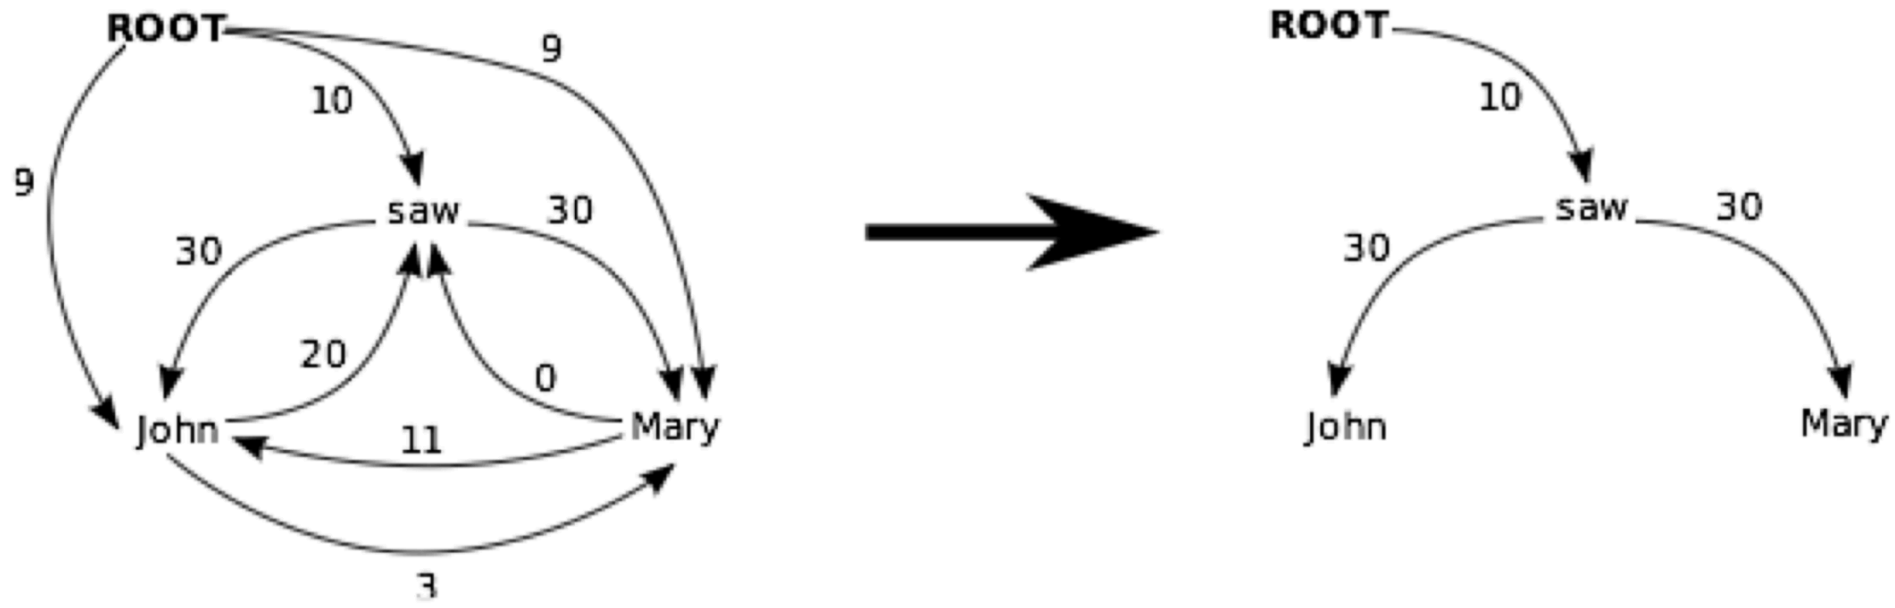

Graph-based Dependency Parsing

- Maximum Spanning Tree - 전형적인 Graph문제
  - Kruskal's algorithm
  - Prim's algorithm
  - 등등
- 근데 Edge의 Weight는?
  - Training Set을 이용하여 통계적인 방법 또는 Machine Learning 방법(SVM, DNN등)을 이용하여 계산할 수 있음
- Transition-Based Dependency Parsing에서와는 다르게 전역적 검색방법
- 그러므로 속도가 훨씬 느림($O(n^2)$ 또는 $O(n^3)$)

Graph-based Dependency Parsing

- Graph based parsing
  - [Stanford] Bi-affine attention model for dependency parsing

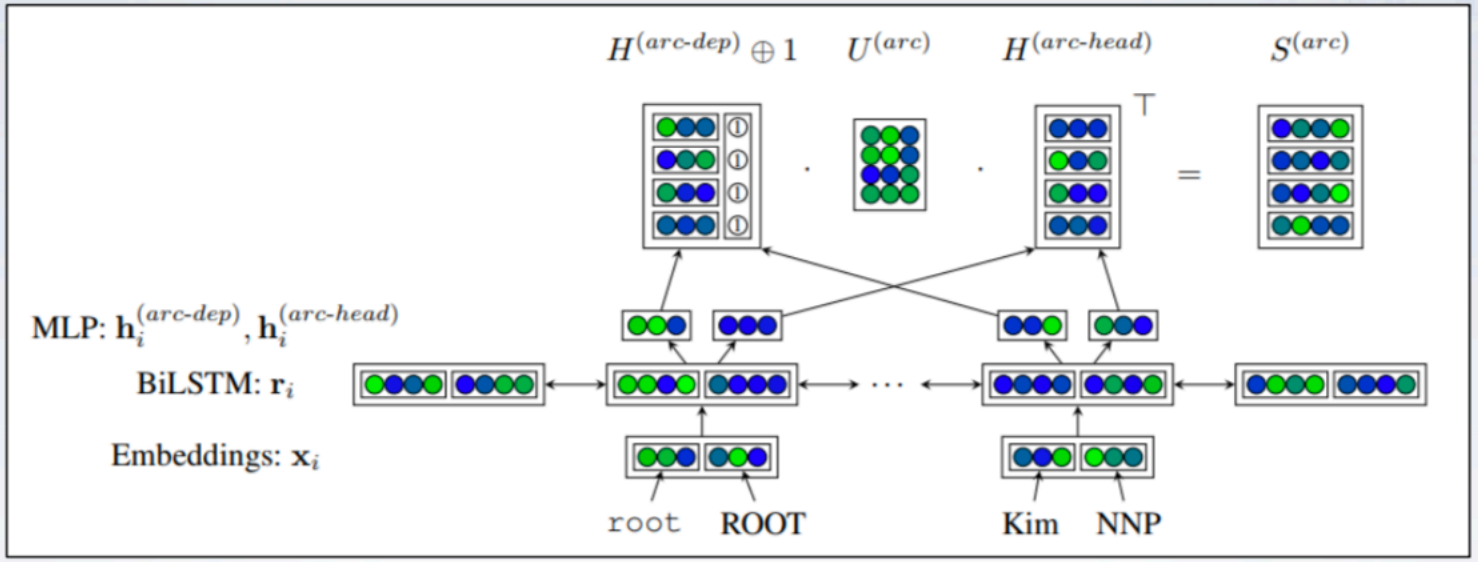

	Recurrent Cell		
Model	**UAS**	**LAS**	**Sents/sec**
LSTM	**95.75**	**94.22**	410.91
GRU	93.18*	91.08*	435.32
Cif-LSTM	95.67	94.06*	**463.25**

Table 2: Test accuracy and speed on PTB-SD 3.5.0. Statistically significant differences are marked with an asterisk.